AI DOC ASSISTANT

ระบบถาม-ตอบเอกสารด้วย RAG ภาษาไทย/อังกฤษ พร้อมอ้างอิงแหล่งที่มา (pilot ภายใน)

System Architecture

รหัสเอกสาร	ADA-DOC-02
ฉบับ	0.1
วันที่	2026-10-07
สถานะ	ร่างเพื่อพิจารณา

เอกสารภายในฉบับร่าง — ใช้ประกอบการพัฒนาและดูแลระบบ

สารบัญ

1. Context diagram

2. Components

3. Tech stack

4. Data stores

5. Integrations

6. Deployment topology

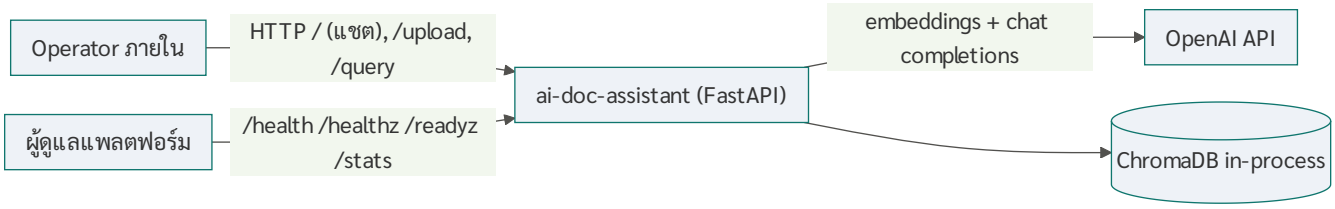
7. ADR สำคัญ

การอนุมัติ

แหล่งข้อมูล

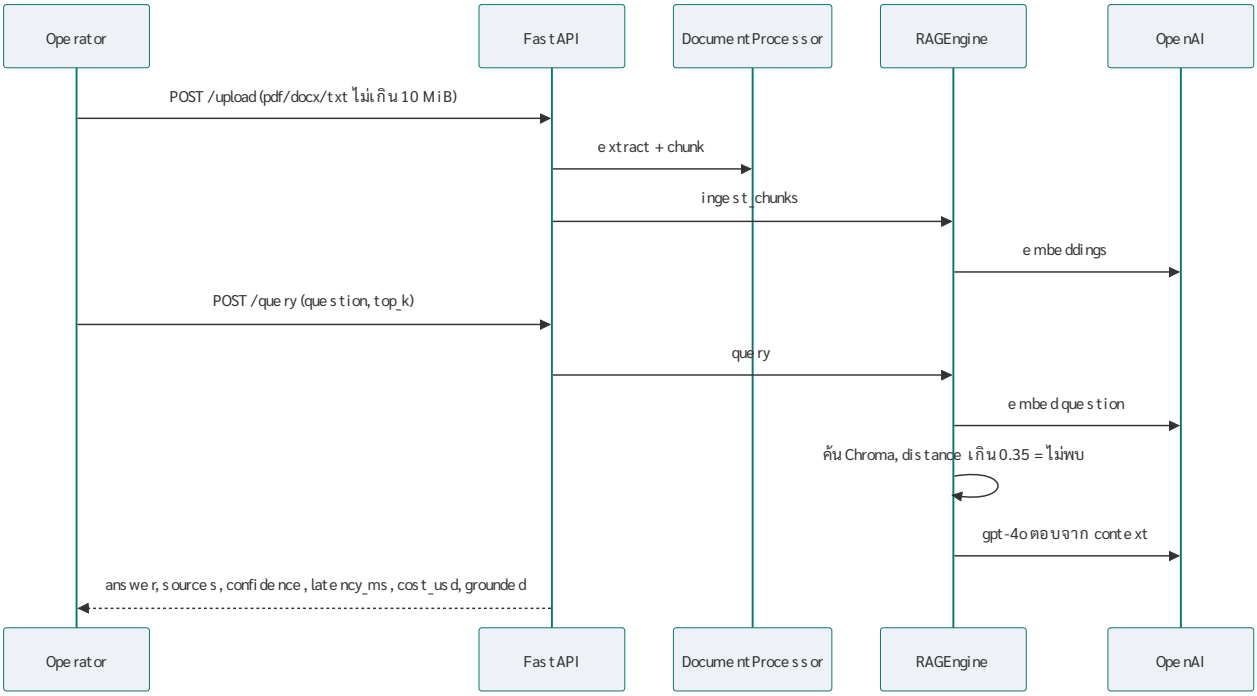
02 — System Architecture

1. Context diagram



2. Components

Component	หน้าที่	ไฟล์
API + UI host	FastAPI, CORS allow-list จาก `CORS_ALLOW_ORIGINS`, เสิร์ฟ `static/index.html` ที่ `/`	`main.py`
Document processor	อ่าน PDF (PyPDF2), DOCX (python-docx), TXT แล้วตัด chunk ขนาด 500 อักขระ overlap 50	`document_processor.py`
RAG engine	สร้าง embedding (`text-embedding-3-small`), ค้น Chroma (cosine), ตัดสิน no-evidence เมื่อ distance > 0.35, สร้างคำตอบด้วย `gpt-4o` (temperature 0.3), คำนวณ cost/latency	`rag_engine.py`
Prompt boundary	ห่อ context ใน `<retrieved_context>` และสั่งให้ถือเป็นข้อมูลที่ไม่น่าเชื่อถือ	`rag_engine.py`
OpenAI client	สร้างแบบ lazy — health/readiness ไม่ต้องใช้ key; upload/query คืน 503 ถ้าไม่มี key	`rag_engine.py`, `main.py`



3. Tech stack

Python 3.11 (Docker image `python:3.11-slim`), FastAPI ≥0.115, uvicorn, ChromaDB ≥0.5, openai ≥1.50, PyPDF2, python-docx, pydantic 2, numpy <2.0; UI เป็น HTML/JS ไฟล์เดียว (`static/index.html`)

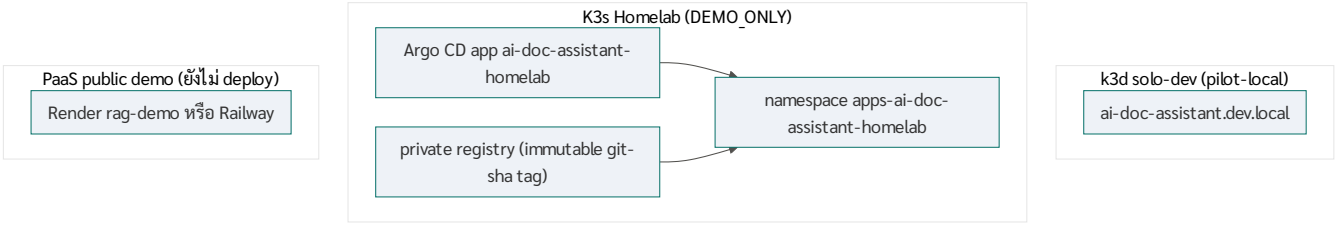
4. Data stores

Store	สถานะ	หมายเหตุ
ChromaDB collection `knowledge_base`	in-memory (`chromadb.Client()`)	หายเมื่อ restart; disk `/app/chroma-data` ใน `render.yaml`/Dockerfile ยังไม่ถูกใช้โดยโค้ด
ไฟล์อัปโหลด	temp file ลบทันทีหลังประมวลผล	ไม่เก็บต้นฉบับ
Staging (แผน)	Postgres + pgvector หรือ Qdrant, object storage S3-compatible	placeholder, `deploymentEnabled: false`

5. Integrations

- OpenAI API (embedding + chat) ผ่านตัวแปร `OPENAI_API_KEY`; ยังไม่ผ่าน Central AI Gateway **[ต้องยืนยัน]** ว่าต้องย้ายหรือไม่ (DEC-AIDOC-004: ห้ามตั้ง provider จนกว่าจะอนุมัติเงื่อนไข งบ และ reviewer)
- ไม่มีการเชื่อม CRM/อีเมล — `OUTREACH.md` เป็นร่างเท่านั้น

6. Deployment topology



- Helm chart กลาง `infra/platform/helm/solo-app`; probe `/healthz` (liveness/startup), `/readyz` (readiness); request 100m/256Mi, limit 1 CPU/1Gi, HPA 1–2 replicas (`infra/platform/onboarding/apps/ai-doc-assistant.yaml`)
- เป้าหมาย PaaS: `STATUS` / `DEPLOY-WHEN-KEY` ระบุ Render, `DEPLOYMENT.md` แนะนำ Railway — **[ต้องยืนยัน]** ผู้ให้บริการที่จะใช้

7. ADR สำคัญ

ID	การตัดสินใจ	สถานะ
ADR-01 (DEC-AIDOC-001)	Chroma ชั่วคราว + เอกสารสังเคราะห์ = demo-only	อนุมัติสำหรับ local/Homelab
ADR-02 (DEC-AIDOC-003)	Upload allow-list, 10 MiB, temp path สุ่ม, ลบไฟล์, error จำกัดรายละเอียด, CORS จำกัด	ทำแล้วใน `815d8e7`; รอ security review

ID	การตัดสินใจ	สถานะ
ADR-03 (DEC-AIDOC-004)	ไม่ตั้ง provider จนกว่าอนุมัติ	blocked
ADR-04 (DEC-AIDOC-006)	ปิด release สาธารณะ/ลูกค้าจนกว่าผ่านทุก gate	proposed
ADR-05	Health ไม่ต้องพึ่ง provider (lazy client)	ทำแล้ว

การอนุมัติ

บทบาท	สถานะ	วันที่	ลงนาม
Solution Architect	ร่างเพื่อพิจารณา	2026-10-07	—
Accountable sponsor	รอพิจารณา	—	—

แหล่งข้อมูล

- `engagements/internal/solo-empire/ai-doc-assistant/main.py`, `rag_engine.py`, `document_processor.py`, `Dockerfile`, `render.yaml`, `railway.toml`, `DEPLOYMENT.md`, `requirements.txt`
- `infra/platform/onboarding/apps/ai-doc-assistant.yaml`, `infra/platform/gitops/applications/values/staging/ai-doc-assistant.yaml`
- `operations/ai/AI-DOC-ASSISTANT-HOMELAB-RUNBOOK.md`
- `roles/pilots/ai-doc-assistant/decision-log.md`, `architecture-decision.md`